Université de Caen Normandie

IUT Grand Ouest Normandie

Bachelor Universitaire de Technologie
Sciences des Données
Antenne de Lisieux

SD 1ére année - SAE 2-03

Régression sur données réelles

Thématique

Etude de l'indice de masse maigre

Groupe

DEFRETIN Matthias
DUPUI Thibaut
JOSEPH--GENESLAY Oscar

Année universitaire 2022-2023

Table des matières

Introduction 3
Analyse exploratoire (1/2) 5
Identification de valeurs aberrantes ou atypique 5
Identification de valeur manquantes 5
Représentation de la distribution des variables d'intérêt 6
Histogramme et densités lissées 7
Nuage de dispersion FFMI vs variables morphologiques 7
Analyse exploratoire (2/2) 8
Nouvelle représentation des nuages de dispersion après filtrage 8
Intensité de l'association linéaire entre la variable FFMI et chacune des variables morphologiques 9
Modélisation 10
Tableau de synthèse via la librairie modelsummary 10
Visualisation et interprétation du meilleur modèle 11
Nuage de dispersion associé au meilleur modèle de régression 11
Tables des illustrations 12

Introduction

Le site https://www.kaggle.com/ met à disposition plusieurs dataset, dans le cadre de la SAE nous allons nous intéresser au fichier nommé BodyFat.csv.

Ce jeu de données contient en particulier les informations suivantes (cf. Image 1) :

- Le nombre de cas (case)
- Densité déterminée par pesée sous-marine (density)
- Âge (années) (age)
- Poids (livres) (height)
- Taille (pouces) (height)
- Tour de cou (cm) (neck)
- Tour de poitrine (cm) (chest)
- Tour de taille (cm) (abdomen)
- Tour de hanches (cm) (hip)
- Tour de cuisse (cm) (thigh)
- Tour de genou (cm) (knee)
- Tour de cheville (cm) (ankle)
- Tour de biceps (étendu) (cm) (biceps)
- Tour de avant-bras (cm) (forearm)
- Tour de poignet (cm) (wrist)

	case	density	age	weight	height	neck	chest	abdomen	hip	thigh	knee	ankle	biceps	forearm	wrist
1	1	1.0708	23	69.96662	1.72085	36.2	93.1	85.2	94.5	59.0	37.3	21.9	32.0	27.4	17.1
2	2	1.0853	22	78.58488	1.83515	38.5	93.6	83.0	98.7	58.7	37.3	23.4	30.5	28.9	18.2
3	3	1.0414	22	69.85322	1.68275	34.0	95.8	87.9	99.2	59.6	38.9	24.0	28.8	25.2	16.6
4	4	1.0751	26	83.80119	1.83515	37.4	101.8	86.4	101.2	60.1	37.3	22.8	32.4	29.4	18.2
5	5	1.0340	24	83.57439	1.80975	34.4	97.3	100.0	101.9	63.2	42.2	24.0	32.2	27.7	17.7
6	6	1.0502	24	95.36780	1.89865	39.0	104.5	94.4	107.8	66.0	42.0	25.6	35.7	30.6	18.8
7	7	1.0549	26	82.10022	1.77165	36.4	105.1	90.7	100.3	58.4	38.3	22.9	31.9	27.8	17.7
8	8	1.0704	25	79.83226	1.84150	37.8	99.6	88.5	97.1	60.0	39.4	23.2	30.5	29.0	18.8
9	9	1.0900	25	86.63614	1.87960	38.1	100.9	82.5	99.9	62.9	38.3	23.8	35.9	31.1	18.2
10	10	1.0722	23	89.92469	1.86690	42.1	99.6	88.6	104.1	63.1	41.7	25.0	35.6	30.0	19.2
11	11	1.0830	26	84.48158	1.89230	38.5	101.5	83.6	98.2	59.7	39.7	25.2	32.8	29.4	18.5
12	12	1.0812	27	97.97595	1.93040	39.4	103.6	90.9	107.7	66.2	39.2	25.9	37.2	30.2	19.0
13	13	1.0513	32	81.87342	1.76530	38.4	102.0	91.6	103.9	63.4	38.3	21.5	32.5	28.6	17.7
14	14	1.0505	30	93.09983	1.80975	39.4	104.1	101.8	108.6	66.0	41.5	23.7	36.9	31.6	18.8
15	15	1.0484	35	85.16197	1.76530	40.5	101.3	96.4	100.1	69.0	39.0	23.1	36.1	30.5	18.2
16	16	1.0512	35	73.82216	1.67640	36.4	99.1	92.8	99.2	63.1	38.7	21.7	31.1	26.4	16.9
17	17	1.0333	34	88.79071	1.80340	38.9	101.9	96.4	105.2	64.8	40.8	23.1	36.2	30.8	17.3
18	18	1.0468	32	94.91420	1.80340	42.1	107.6	97.5	107.0	66.9	40.0	24.4	38.2	31.6	19.3
19	19	1.0622	28	83.34760	1.72085	38.0	106.8	89.6	102.4	64.2	38.7	22.9	37.2	30.5	18.5
20	20	1.0610	33	96.04818	1.86690	40.0	106.2	100.5	109.0	65.8	40.6	24.0	37.1	30.1	18.2

Image 1 : Extrait des données concernant les mesures corporelles

Il a été décidé de rajouter à ces données les informations suivantes issue de différent calculs (cf. Image 2) :

- Siri : représentant le pourcentage de masse graisseuse (ou **Body Fat**) calculé selon l'indicateur **density**
- FFM : représentant la quantité de masse maigre (ou **Fat Free Mass**) calculée selon l'indicateur **Siri**
- FFMI : Indices de masse maigre (ou **Fat Free Mass Index**) calculée selon les indicateurs **FFM** et **height**

siri	FFM	FFMI
12.2711991	61.38088	20.72751
6.0950889	73.79506	21.91211
25.3216824	52.16521	18.42221
10.4222863	75.06719	22.28984
28.7234043	59.56898	18.18792
21.3387926	75.01746	20.81002
19.2387904	66.30513	21.12474
12.4439462	69.89797	20.61205
4.1284404	83.05942	23.51029
11.6675993	79.43264	22.79066
7.0637119	78.51404	21.92640
7.8246393	90.30969	24.23482
20.8456197	64.80640	20.79605
21.2041885	73.35877	22.39829
22.1480351	66.30027	21.27542
20.8904110	58.40041	20.78072
29.0477112	62.99904	19.37090
22.8696981	73.20761	22.50982
16.0139333	70.00037	23.63819

Image 2: extrait des données rajoutés

On se propose dans la suite de réaliser une analyse exploratoire de ces données, le rapport va se scinder en 3 parties :

- Analyse exploratoire (1/2)
- Analyse exploratoire (2/2)
- Modélisation

Analyse exploratoire (1/2)

Identification de valeurs aberrantes ou atypique

Afin de détecter la présence de valeurs aberrantes ou atypique, nous avons utilisé la fonction summary() et obtenus la sortie suivante : (cf. Image 3)

```
      neck           chest           abdomen           hip             thigh           knee           ankle
 Min.   :31.87   Min.   : 79.30   Min.   : 69.40   Min.   : 85.00   Min.   :47.20   Min.   :34.04   Min.   :20.00
 1st Qu.:36.40   1st Qu.: 94.35   1st Qu.: 84.58   1st Qu.: 95.50   1st Qu.:56.00   1st Qu.:36.98   1st Qu.:22.00
 Median :38.00   Median : 99.65   Median : 90.95   Median : 99.30   Median :59.00   Median :38.50   Median :22.80
 Mean   :37.97   Mean   :100.74   Mean   : 92.43   Mean   : 99.73   Mean   :59.41   Mean   :38.54   Mean   :23.02
 3rd Qu.:39.42   3rd Qu.:105.38   3rd Qu.: 99.33   3rd Qu.:103.53   3rd Qu.:62.35   3rd Qu.:39.92   3rd Qu.:24.00
 Max.   :44.00   Max.   :121.93   Max.   :121.46   Max.   :115.50   Max.   :87.30   Max.   :42.86   Max.   :26.00
     biceps          forearm          wrist            FFMI
 Min.   :26.00   Min.   :24.00   Min.   :16.50   Min.   :16.70
 1st Qu.:30.20   1st Qu.:27.30   1st Qu.:17.60   1st Qu.:18.99
 Median :32.05   Median :28.70   Median :18.30   Median :20.33
 Mean   :32.24   Mean   :28.68   Mean   :18.22   Mean   :20.33
 3rd Qu.:34.33   3rd Qu.:30.00   3rd Qu.:18.80   3rd Qu.:21.33
 Max.   :38.00   Max.   :33.00   Max.   :20.00   Max.   :26.00
```

Image 3: Sortie de la fonction summary()

Analyse. Observer qu'il n'y aucune valeur aberrantes (exemple : une valeur négative), il y a tout de même quelques valeurs atypiques, voyez la valeur Max. des variables chest et abdomen, l'écart entre le 3^{éme} quartile et le Max. est conséquent par rapport aux variables étudiées.

Identification de valeur manquantes

Voyons maintenant l'existence potentielle de valeur manquante à l'aide de la fonction sum(is.na()) qui va faire la somme de toutes les valeurs marquées « na » : (cf. Image 4)

```
[1] 0
```

Image 4: Sortie de la fonction sum(is.na())

Analyse. Grâce à cette fonction effectuer sur nos variables d'intérêt « data » (laquelle est prise en argument lors de l'appel de la fonction) nous pouvons observer l'absence de valeur manquante.

Représentation de la distribution des variables d'intérêt

Poursuivons la détection de variables atypiques sous forme de graphique à l'aide de la fonction boxplot() pour avoir une meilleure précision: (cf. Image 5)

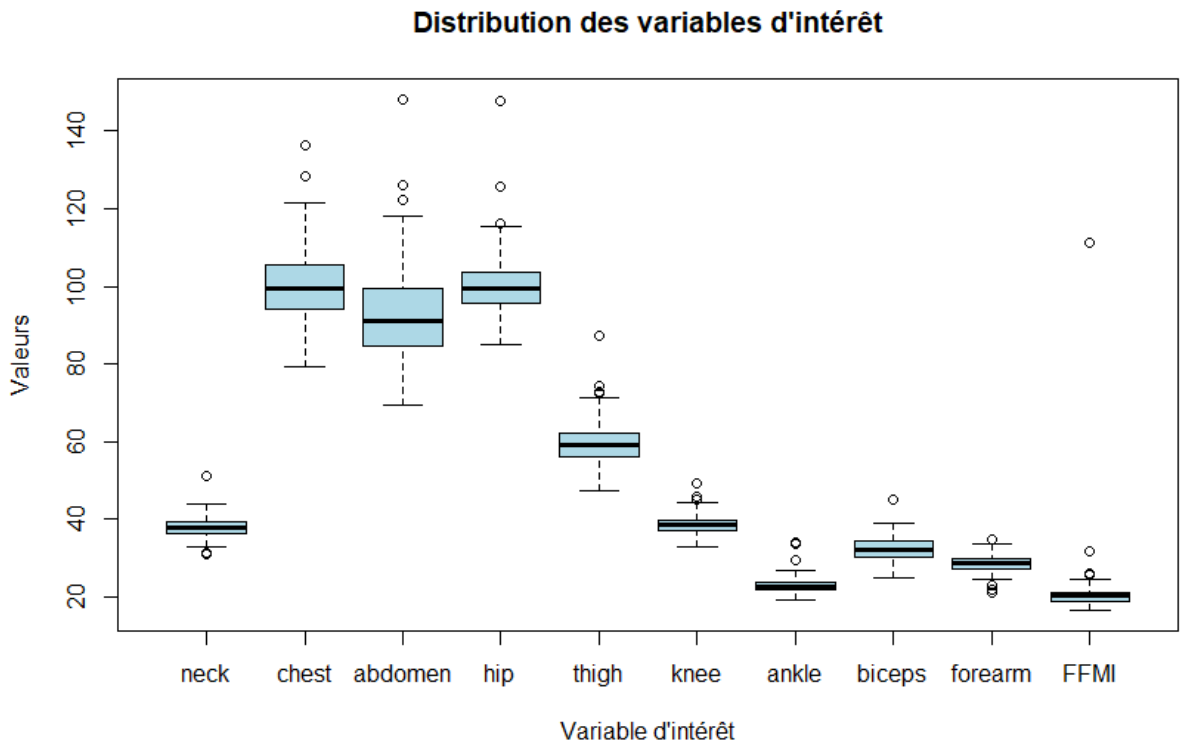

Image 5: Sortie de la fonction boxplot()

Analyse. Maintenant, à l'aide de ce graphique nous avons détecter davantage de valeur atypique pour chacune des variables d'intérêt au-dessus et en dessous des extrémités des boîtes sous forme de petit cercle.

Histogramme et densités lissées

Intéressons-nous maintenant à la distribution des variables d'intérêts en utilisant des histogrammes avec courbe de densité lissées : (cf. Image 6)

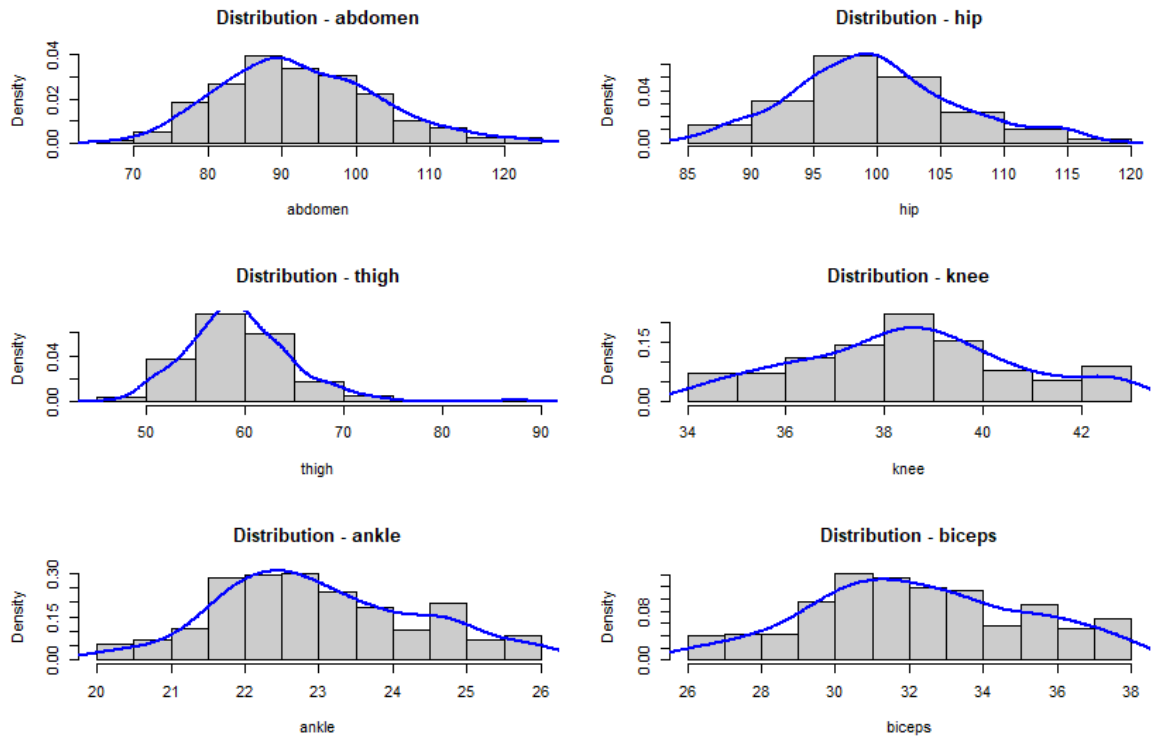

Image 6 : Histogramme et densités lissées

Analyse. Nous pouvons observer que les résidus se situent aux alentours de zéro et que le modèle de régression linéaire est approprié.

Nuage de dispersion FFMI vs variables morphologiques

Attardons-nous maintenant à la variable FFMI croisé avec chacune des variables morphologiques dans un nuage de dispersion avec une courbe de régression lissée (ici en rouge) (cf. Image 7) :

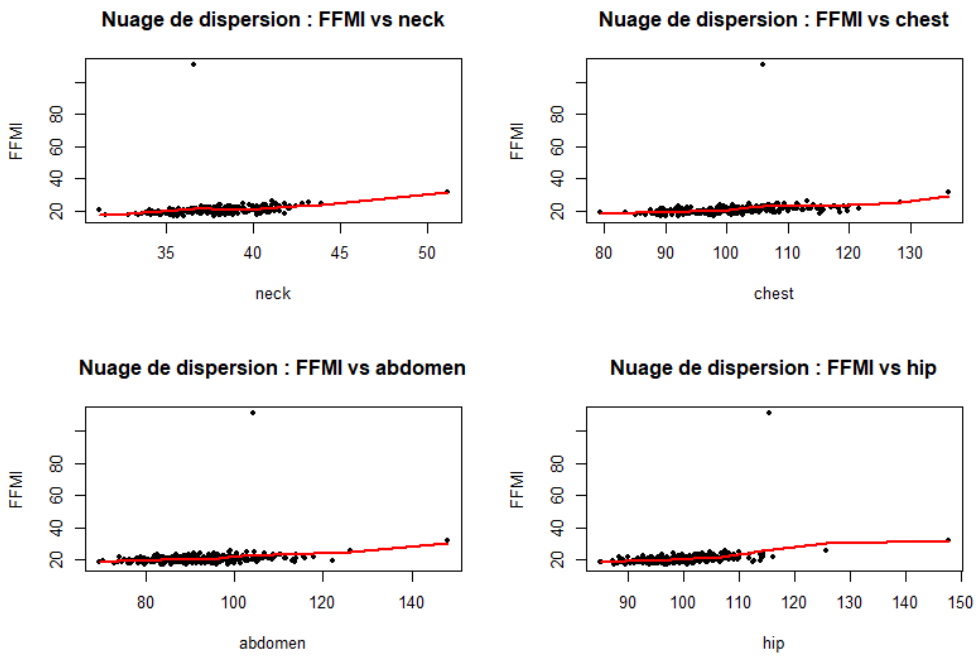

Image 7 : Sortie graphique FFMI vs variable morphologiques

Analyse. Nous pouvons observer sur les quatre graphiques ci-dessus l'apparition de variable atypique, le plus souvent dans la partie supérieure du graphique.

Analyse exploratoire (2/2)

Nouvelle représentation des nuages de dispersion après filtrage

Après élimination par filtrage des observations présentant des valeurs atypiques, nous obtenons ces 4 graphiques ci-dessous : (cf. Image 8)

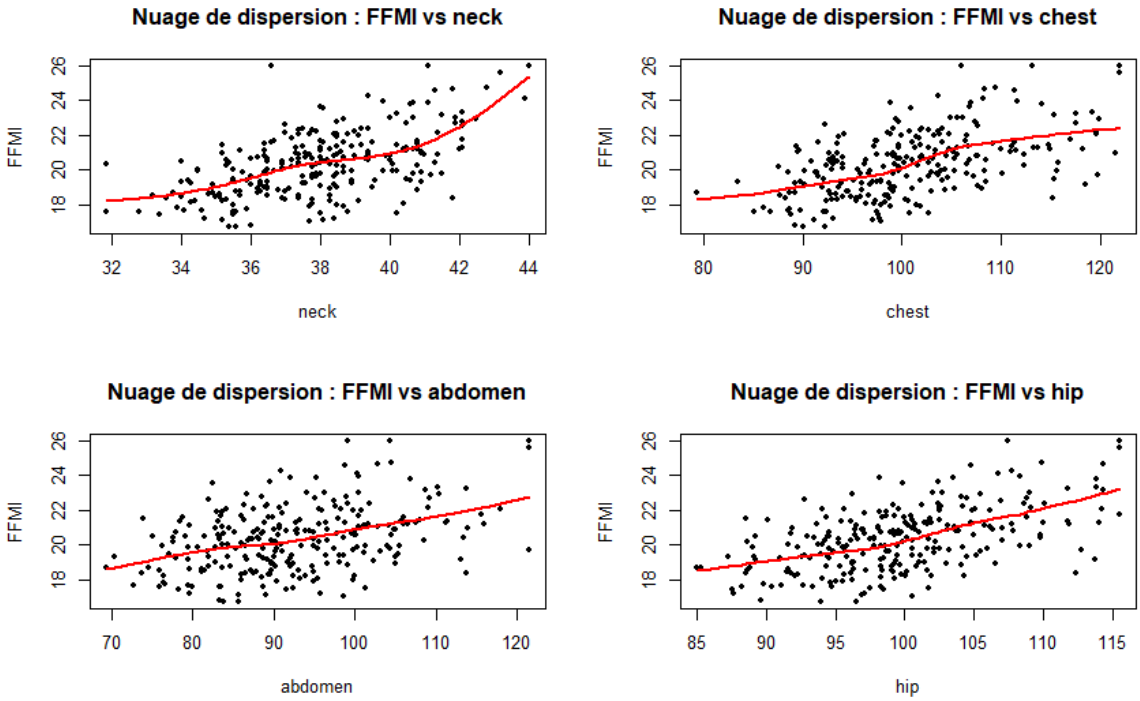

Image 8: Sortie graphique FFMI vs variables morphologiques après filtrage

Analyse. Nous pouvons observer sur les quatre graphiques ci-dessus l'apparition de variable atypique, le plus souvent dans la partie supérieur droite cette fois-ci.

Intensité de l'association linéaire entre la variable FFMI et chacune des variables morphologiques

Sous forme de tableau à l'aide de la librairie flextable, nous allons voir la corrélation entre les variables FFMI et les variables morphologiques (cf. Image 9) :

Corrélation FMMI & variables morphologiques

neck	chest	abdomen	hip	thigh	knee	ankle	biceps	forearm	wrist
55.9	52.6	39.18	54.73	57.38	49.49	48.71	53.48	50.97	52.75

Image 9 : FMMI & varialbes morphologiques

Modélisation

Tableau de synthèse via la librairie modelsummary

Voyons maintenant une synthèse des régressions linéaire pour chaque variable explicative à l'aide de la librairie modelsummary (cf. Image 10) :

	Model1	Model2	Model3	Model4	Model5	Model6	Model7	Model8	Model9	Model10
(Intercept)	3.325	8.357	13.844	4.689	8.358	4.484	4.930	9.324	6.185	0.103
	(1.598)	(1.229)	(0.970)	(1.516)	(1.085)	(1.763)	(1.749)	(1.104)	(1.513)	(2.063)
neck	0.448									
	(0.042)									
chest		0.119								
		(0.012)								
abdomen			0.070							
			(0.010)							
hip				0.157						
				(0.015)						
thigh					0.202					
					(0.018)					
knee						0.411				
						(0.046)				
ankle							0.669			
							(0.076)			
biceps								0.341		
								(0.034)		
forearm									0.493	

Image 10 : synthèse régressions linéaire

									(0.053)	
wrist										1.111
										(0.113)
Num.Obs.	252	252	252	252	252	252	252	252	252	252
R2	0.313	0.277	0.154	0.300	0.329	0.245	0.237	0.286	0.260	0.278
R2 Adj.	0.310	0.274	0.150	0.297	0.327	0.242	0.234	0.283	0.257	0.275
AIC	934.3	947.1	986.7	939.0	928.1	957.9	960.4	943.8	952.9	946.5
BIC	944.8	957.6	997.3	949.6	938.7	968.5	971.0	954.4	963.5	957.1
Log.Lik.	−464.128	−470.529	−490.348	−466.483	−461.038	−475.952	−477.215	−468.897	−473.434	−470.264
RMSE	1.53	1.57	1.69	1.54	1.51	1.60	1.61	1.56	1.58	1.56

Analyse. Le meilleur modèle parmi ceux présent est le model1 : neck

Visualisation et interprétation du meilleur modèle

Voici une visualisation plus précise du meilleur modèle a l'aide de la fonction summary() (cf. Image 11) :

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.32523    1.59825   2.081   0.0385 *
neck         0.44795    0.04202  10.661   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.532 on 250 degrees of freedom
Multiple R-squared:  0.3125,    Adjusted R-squared:  0.3098
F-statistic: 113.7 on 1 and 250 DF,  p-value: < 2.2e-16
```

Image 11 : Sortie de la fonction summary()

Analyse. Pour une augmentation de 1 cm de la variable neck, on observe une augmentation moyenne de l'indice de masse maigre (FFMI) de 0.45 unité. C'est à dire que, pour 2 arbres ayant une circonférence de 1 cm de différence, l'écart de leur indice de masse maigre (FFMI) serait d'environ 0.45 unité.

Nuage de dispersion associé au meilleur modèle de régression

Voyons enfin le nuage de dispersion croisant FFMI avec le meilleur modèle de régression (cf. Image 12) :

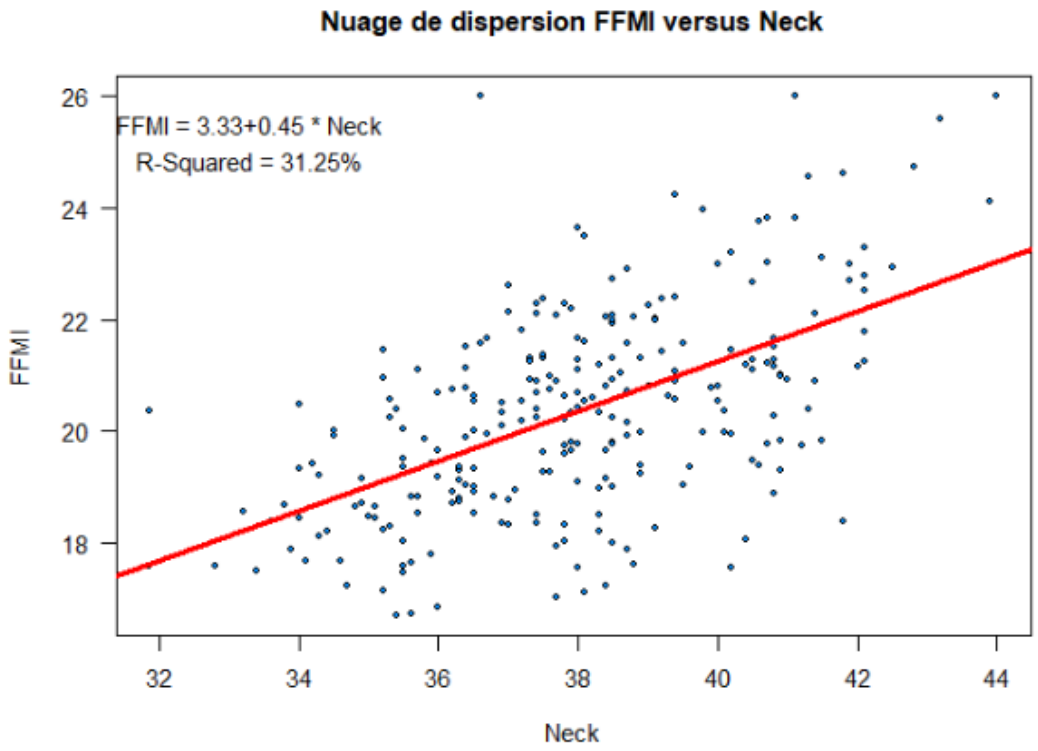

Image 12 : FFMI versus Neck

Tables des illustrations

Image 1 : Extrait des données concernant les mesures corporelles 3
Image 2: extrait des données rajoutés 4
Image 3: Sortie de la fonction summary() 5
Image 4: Sortie de la fonction sum(is.na()) 5
Image 5: Sortie de la fonction boxplot() 6
Image 6 : Histogramme et densités lissées 7
Image 7 : Sortie graphique FFMI vs variable morphologiques 7
Image 8: Sortie graphique FFMI vs variables morphologiques après filtrage 8
Image 9 : FMMI & varialbes morphologiques 9
Image 10 : synthèse régressions linéaire 10
Image 11 : Sortie de la fonction summary() 11
Image 12 : FFMI versus Neck 11